

AFP讨论

重思考自己工作的落脚点：强调AI方法在新功能肽体系下的有效应用，批量提出有效候选者+提出几条优质候选者

方法学逻辑上与这两篇工作类比：

NM（预测-生成-验证）：<https://www.nature.com/articles/s41564-025-02114-4>

NBE（预测-验证）：<https://www.nature.com/articles/s41551-026-01630-w>

值得一提的是，NBE这篇重点强调了方法学，其实最终的结果从叙事来看只能说是找到了批量+有效的，而并非领域最好的。

迁移到抗冻肽体系（此前这个体系上没有任何工作使用过AI筛选的方法）

体系是如下工作的体系：

NC：<https://www.nature.com/articles/s41467-021-22883-w> 最早的抗冻肽挖掘工作

Engineering：<https://www.sciencedirect.com/science/article/pii/S2095809923002114>

JACS：<https://pubs.acs.org/doi/10.1021/jacs.4c18537>

研究思路




清华大学 化学工程系
Department of Chemical Engineering, Tsinghua University

总体思路：搭建面向高性能功能肽挖掘的通用闭环设计框架

预测-生成-模拟-实验闭环

Step1: 挖掘功能蛋白候选



序列/结构输入

功能蛋白
预测器

高质量
蛋白候选




功能蛋白训练集


深度生成
模型

候选生成蛋白库

Step2: 挖掘功能肽候选



Step3: 验证分析



分子动力学模拟



机理发现



湿实验分析

由于抗冻肽本身的数据稀缺性，采用先挖掘抗冻蛋白，再从抗冻蛋白中识别功能 motif 并下切为候选抗冻肽的总体路线。

一. 体系选取

为什么选取抗冻肽这个体系？

1) 工程应用意义

- 抗冻蛋白（AFP）因其独特的热滞后效应及冰晶重结晶抑制机制，能够在微观物理层面精准调控冰晶生长，有效避免低温下的细胞机械损伤。这一特性赋予了其在无毒器官冷冻保存、冷冻疗法及食品工业等领域不可替代的应用价值。
- 抗冻肽（AFPT）可被视为小型抗冻蛋白，由于它们同样能够结合冰晶晶格，同时免疫原性更低、也更容易调控，因此被认为是最有前景的工程替代方案。（同时实验更好合成+验证，迭代更快）

2) 数据稀缺性

- 抗冻肽不像抗菌肽、抗癌肽有丰富、成型的数据库。抗冻肽的设计和挖掘本身就是个很稀疏的问题。目前公布的有效果的抗冻肽仅一百余条（抗冻蛋白一万条左右）。**能 1) 找出新的抗冻多肽/2) 给出新的批量挖掘方法/3) 给出抗冻机理解释以助力后续挖掘且效果不错是很有意义的**

3) 真实作用机理不明确、筛选方法缺少逻辑性

- 抗冻肽设计这个子领域很新，目前其抑制冰晶结冰的机理尚不明确，目前尚无统一理论，大多工作是自圆其说
- 现有工作的筛选逻辑存在“先射箭，再画靶”的可能性。

目前已有的部分工作：

2021.5: NC: <https://www.nature.com/articles/s41467-021-22883-w> 抗冻肽挖掘领域较为成形的最早工作

2024.3 Engineering: <https://www.sciencedirect.com/science/article/pii/S2095809923002114> 挖掘出1条高效肽

2025.4 JACS: <https://pubs.acs.org/doi/10.1021/jacs.4c18537> 提出潜在抗冻机理并合成6条有效肽性能很好

二. 工作创新点

创新点一：抗冻肽挖掘体系本身的意义，解决目前已有肽段样本少、工程不可及、性能不够好

创新点二：在这个体系下首次提出AI预测-生成-实验验证的设计框架，先挖掘抗冻蛋白再从抗冻蛋白中识别功能 motif得到短肽，解决1) 无批量挖掘方案 2) 设计逻辑感不强的问题

1) 预测器创新点

- 开发的单模型性能优于现有已发表 AFP 预测器
- 提出多预测器级联筛选（类似voting）可在保证通量的同时尽量降低假阳性
- 不同模型对同一序列的打分分布存在明显差异，具备互补纠错潜力

2) 生成器创新点

- 基于已有工作预训练模型: Protgpt2: <https://www.nature.com/articles/s41467-022-32007-7>
- 引入 LoRA 微调方案，并观察到更好的 AFP 命中效果，说明其更适合当前数据规模与目标任务。

3) 如何从蛋白到肽：利用生物信息学工具mmseq聚类、MAFFT多序列比对与保守型分析、MEME进行motif挖掘

创新点三（目前待验证+深入）：尝试提出潜在抗冻机理

发现目前挖掘出来的motif存在共性：

- 亲水疏水氨基酸（一个或者多个）交替出现在冰面形成M/W式结构，这可能是抗冻肽的一种模式。亲水位点与冰面结合，疏水位点提供支撑。
- 观察到motif片段重复形成的二级结构趋向alpha-helix，这篇工作也提到alpha-helix可能是有助于抗冻性能：<https://pubs.acs.org/doi/10.1021/acsami.5c17507>

三. 工作开展情况


AI预测-生成部分

1. 抗冻蛋白预测器开发（已完成）

分子动力学模拟得到标签重新训条件生成 肽预测器

预测器+生成器（0，1label） 标签来源于生成的合成数据

为什么能好？



1) 目标：构建多个 AFP 预测器，对天然蛋白库和生成蛋白库进行轮询筛选，形成类似 predictor voting 的框架，以降低单模型误判带来的假阳性率。

2) 训练数据主要包括：

- UniProt：约 7k-8k 条正样本 + 8k 左右负样本，参考 AFPropred 工作数据，长度限制为 `<1022 aa`

- Swiss-Prot 金标准集：作为独立验证集，用于对标现有 AFP 预测工作

3) 数据划分与验证策略

- UniProt 数据按 `9:1` 划分为训练集和测试集；Swiss-Prot 作为独立验证集
- 思路对标 AFPDeepPred 类工作：<https://pubs.acs.org/doi/10.1021/acs.jcim.5c02024>

4) 模型设计

- SaProt/ESM2/SaProt + ESM2 融合模型 共三类模型

开展以下消融实验：

- 不同蛋白语言模型作为基座的影响
- 采用 fusion 策略的影响
- 末端预测器的选择

2. 抗冻蛋白生成器构建（已完成/但未做更多补充实验）

目前只聚焦于上述框架的 path1，是最快能迭代出来流程的。后续也可以继续补充 path2/3

1) 目标：基于现有蛋白生成语言模型 ProtGPT2，通过 LoRA 微调，使其更倾向于生成 AFP-like 序列，并利用预测器进行打分筛选，评估生成器是否真正学会了抗冻蛋白的序列模式。

2) 方法：

- 基座模型：Protgpt2: <https://www.nature.com/articles/s41467-022-32007-7>
- 微调方式：引入 LoRA 的 PEFT 方案

- 生成一定数量蛋白后，送入 AFP 预测器评估其命中率

3) 已有结果：LoRA2 微调后生成命中率约为 815/1000 全量微调命中率约为 497/1000

生成序列与训练数据不同源不相似

4) 还需要补充更多统计特征指标、消融实验

开展以下消融实验：

- 不同温度的影响，不同topk选择的影响，不同penalty的意向

图：

训练loss图；消融实验和微调前比较图；生成内容分布图/和远源关系图；聚类大图（标结构的那种）

3. 从蛋白到肽：使用正确的生物信息学工具挖掘motif（部分完成）

1) 分支一：天然蛋白库筛选（已完成）


考虑到 SaProt 和 ESM + SaProt 需要结构输入，因此先采用 ESM2-only 进行快速初筛。

当前做法：

- 从 UniProt 中选取约 64 万条极地生物来源蛋白
- 先由 ESM2-only 快速筛选，得到约 1800 条高置信候选（如 confidence > 0.9）
- 再由另外两个更强的专家预测器进行二次判分
- 后续结合去冗余和注释过滤，仅保留 AFP 明确标注或弱注释条目

另外：<https://www.nature.com/articles/s41587-022-01367-2>

冰川宏基因组数据中预测并翻译得到的约两千万条肽序列纳入了预测肽库，进一步扩大了候选肽筛选空间。相比 UniProt 等已有蛋白数据库，宏基因组数据能够覆盖大量尚未被培养或注释的环境微生物序列，尤其是冰川等极端低温环境中的微生物资源，因此有助于挖掘更具新颖性的潜在抗冻肽候选者。



2) 分支二：生成蛋白筛选（已完成）

- 使用 LoRA 微调的 ProtGPT2 生成约 10000 条蛋白候选
- 再由多个预测器筛选，得到约 8000 条 AFP-like 蛋白

3) 统一生物信息学分析流程（已完成）

对两个分支得到的 AFP 候选，采用统一分析策略：

1. MMseqs2 去冗余与聚类

2. k-mer 统计

- 去除低复杂度片段，例如单一氨基酸占比过高的片段
- 每条序列对同一 motif 最多记一次

3. MAFFT 多序列比对与保守性分析

- 对大簇或重点候选簇开展 MSA；统计逐位点保守度；提取连续保守区


4. MEME motif 挖掘

- 在重点簇中发现统计显著的保守 motif；与 k-mer 和 MSA 结果交叉验证

4) 观察筛选得到的Motif（需要深入验证机理）

分子动力学模拟部分（清楚范式，但未完成）

1. 之前在帮助实验同学补充的时候针对其他的抗冻肽做过md，基本流程已经摸清楚。



湿实验部分（正在开展）

1. 实验1：冰重结晶抑制实验（Ice Recrystallization Inhibition）

初筛作用

将肽置于冰水体系中，在-6/-8摄氏度观察冰晶形成速率。30min后拍照，使用ImageJ图像抓取软件识别冰晶

实验2：肽结构/与水相互作用相关实验 —— （化工系公共实验 平台）

CD（圆二色谱）：肽溶液放进石英比色皿，扫描远紫外区 190–260 nm 的圆二色信号；主要反映肽的二级结构组成和温度稳定性，比如 α -helix、 β -sheet、random coil 的比例。

Raman（拉曼光谱）：激光照射肽溶液，采集分子振动信号。主要反映肽骨架构象和局部化学环境

DSC（差示扫描量热）：按设定升温或降温程序记录样品与参比之间的热流变化，用于肽本身可看结构稳定性，反映冰成核、结晶或相变过程。属于对结构相关性质的间接表征。

实验3：细胞实验 + 相容性实验（最核心，最重要最有价值的实验）

把材料用于细胞冻存并检测细胞活率、恢复增殖和毒性/生物相容性，用来判断它是否既能保护细胞，又不会对细胞造成明显损伤。

画图部分（未完成）

1. 目前还没开始大规模画图，需要尽快补上

四. 目前思考与后续安排

这个工作思路NM：<https://www.nature.com/articles/s41564-025-02114-4>

NBE（预测-验证）：<https://www.nature.com/articles/s41551-026-01630-w>

把部分核心思想用在抗冻肽挖掘、强调流程的全面性和完整性。

目前和这篇工作的差距有几点：1) 筛选规模小于它 2) 不清楚目前挖掘出来的肽的真实效果